

UNIVERSIDAD POPULAR AUTÓNOMA DEL ESTADO DE PUEBLA

Maestría en Pedagogía

PROTOCOLO DE INVESTIGACIÓN

Medir el papel formador del Estado

Seis ejes confucianos aplicados a políticas públicas
de educación en inteligencia artificial de siete países

Hesus García Cobos

Director: Dr. Herminio Sánchez de la Barquera y Arroyo

Puebla, Puebla · 2026

Libro de códigos, configuración y predicciones registrados en control de versiones
antes de ejecutar la medición. Código y datos abiertos.

Índice

1. Resumen del proyecto	3
2. Introducción	3
3. Planteamiento del problema	4
3.1. Contexto	4
3.2. La brecha	4
3.3. El objeto de medición	5
4. Preguntas de investigación	5
5. Objetivos	6
5.1. Objetivo general	6
5.2. Objetivos específicos	6
6. Hipótesis	6
7. Método	7
7.1. Enfoque	7
7.2. Corpus	7
7.3. El caso de México	8
7.4. Muestreo	9
7.5. Los seis ejes	9
7.6. El eje de medición	11
7.7. Vía A: proyección sobre representaciones vectoriales	11
7.8. Vía B: panel de jueces	11
8. Plan de análisis	12
8.1. Acuerdo entre jueces	12
8.2. Sesgo de origen	12

8.3. Pruebas de confusión	13
8.4. Criterio de decisión	13
9. Objeciones anticipadas	13
9.1. El eje trata como opuestos lo que la doctrina china empareja	13
9.2. El acuerdo entre modelos no es validez	14
9.3. El riesgo de esencializar	14
10.Límites declarados	14
11.Trabajo derivado	15
12.Consideraciones éticas	15
13.Cronograma	16
14.Productos comprometidos	16

1. Resumen del proyecto

Cuando dos gobiernos escriben «formación docente en inteligencia artificial», pueden estar diciendo cosas incompatibles. Uno puede entender la educación en IA como cultivo moral de la población dirigido por el Estado; otro, como una conducta que se regula mediante reglas y límites. Esta investigación mide esa diferencia en las políticas nacionales de siete países, uno por región política del mundo.

La medición se ejecuta por dos vías independientes entre sí: una proyección del texto sobre un eje construido con representaciones vectoriales de significado, y un panel de siete modelos de lenguaje de origen cultural mixto que aplican un libro de códigos escrito en prosa. El instrumento del estudio no es ninguna de las dos: es el contraste entre ambas.

Palabras clave: educación comparada, política educativa, inteligencia artificial, medición de texto, validez de instrumentos, confucianismo.

2. Introducción

Los gobiernos del mundo están escribiendo sus políticas de inteligencia artificial para la escuela, y para escribirlas copian de otros países. Es la práctica normal en educación comparada y no hay nada malo en ella. El problema aparece antes: los documentos de los que se copia se parecen tanto entre sí que leerlos uno al lado del otro no revela en qué se diferencian. Todos hablan de formar talento, capacitar docentes y usar la tecnología con ética.

Debajo de ese vocabulario compartido hay una diferencia que sí importa, y es de reparto de papeles. Un documento puede presentar al Estado fijando el plan que las escuelas aplican y los docentes ejecutan, con la población alcanzando el nivel que el propio Estado definió. Otro puede presentar al Estado financiando investigación y poniendo reglas de privacidad, mientras universidades y empresas deciden qué hacer dentro de ese marco. Los dos dicen que hay que formar gente para la inteligencia artificial. No dicen lo mismo sobre quién forma a quién.

Esta investigación construye una forma de medir esa diferencia, la aplica a las políticas nacionales de siete países, uno por región política del mundo, y comprueba si la medición aguanta. Para nombrar los dos polos usa un vocabulario de la tradición confuciana: gobernar por la virtud, *dézhì* (德治), frente a gobernar por la norma, *fǎ* (法). La elección es por precisión, no por afinidad cultural: esa tradición distingue las dos cosas con dos palabras y las discute desde hace dos milenios. El eje se aplica por igual a los siete países, no solo a China.

La medición se ejecuta dos veces, con procedimientos que no comparten supuestos. Esa duplicación no es redundancia. Ninguna de las dos vías produce por separado un resultado interpretable: la primera entrega números sin manera de confirmar que corresponden al constructo, la segunda entrega juicios sin manera de detectar si el panel comparte un sesgo. Solo el contraste entre ambas permite decidir si la medición es creíble, y cuando las dos discrepan, el desacuerdo señala dónde está el problema. Es la única forma disponible de someter a prueba un instrumento cuando no existe un patrón de oro contra el cual calibrarlo.

3. Planteamiento del problema

3.1 Contexto

Para 2023, al menos 67 países habían formulado o estaban formulando estrategias nacionales de inteligencia artificial (UNESCO, 2023). En la mayoría, la educación aparece como componente de desarrollo de talento para la competitividad económica, no como objeto de política educativa en sí mismo. Formar ingenieros de IA no es lo mismo que preparar a todos los estudiantes para vivir en un mundo transformado por ella.

Esa proliferación produjo un problema de lectura. Los documentos se parecen entre sí. Comparten vocabulario, estructura y hasta secuencia de secciones. Steiner-Khamsi (2014) distingue tres explicaciones posibles para ese parecido: préstamo deliberado de un país a otro, influencia común de un marco internacional, o convergencia funcional entre países que enfrentan el mismo problema sin contacto entre sí. Decidir cuál opera requiere más que leer los documentos uno al lado del otro.

3.2 La brecha

La educación comparada ha incorporado herramientas de similitud semántica para analizar corpus multilingües, tratando los textos de política como datos (Grimmer and Stewart, 2013). Estas herramientas miden cuánto se parecen dos textos en un espacio de significado y permiten comparar sin traducir.

El supuesto implícito es que la similitud detectada por esas herramientas indica convergencia de política. Ese supuesto no ha sido puesto a prueba de manera sistemática. Y hay razones para dudarlo: Bareis and Katzenbach (2022) observaron cualitativamente que las narrativas de las estrategias nacionales de IA son notablemente similares mientras que los imaginarios que expresan son notablemente distintos.

Falta entonces un estudio que mida un constructo teórico definido por adelantado, lo mida por dos caminos independientes, y reporte si coinciden.

3.3 El objeto de medición

Esta investigación mide **a quién le corresponde formar a las personas** según cada documento de política.

La tradición confuciana nombra esa oposición desde hace dos milenios. Gobernar por la virtud, *dézhì* (德治), sostiene que la autoridad legítima educa con el ejemplo y forma el carácter de los gobernados. Gobernar por la norma, *fǎ* (法), sostiene que la autoridad se ejerce mediante reglas públicas iguales para todos, con premio y castigo previsibles (Pines, 2023).

La oposición no es exclusiva de China. Es la misma tensión que atraviesa la teoría política occidental entre el Estado formador y el Estado limitado. Lo que la tradición china aporta es un vocabulario preciso para nombrarla y un cuerpo de literatura de dos milenios que la discute.

4. Preguntas de investigación

¿Las políticas de educación en inteligencia artificial de siete países expresan concepciones distintas sobre quién forma a las personas, y esa diferencia se puede medir de manera reproducible?

De la pregunta central se desprenden tres, una por cada cosa que hay que resolver para responderla.

- P1.** **¿Se puede medir?** ¿Es posible asignar a un pasaje de política pública un valor que exprese cuánto encuadra la educación en IA como cultivo moral dirigido por el Estado, frente a cuánto la encuadra como conducta regulada por normas?
- P2.** **¿Difieren los países?** ¿Se separan los siete países en ese eje, y la separación sobrevive cuando se controla por la región del documento, por su tema y por la estructura del Estado?
- P3.** **¿Coinciden los métodos?** ¿Dos procedimientos de medición independientes, uno por proyección vectorial y otro por juicio de lectura, producen el mismo ordena-

miento de países? Si no coinciden, ¿qué revela el desacuerdo? Y dentro del panel de lectores, ¿el origen cultural de cada uno sesga su propia calificación?

P1 es una pregunta de instrumento, P2 de comparación y P3 de validez. Las tres se responden con el mismo corpus.

5. Objetivos

5.1 Objetivo general

Medir en las políticas de educación en inteligencia artificial de siete países el grado en que el Estado se presenta como formador moral de la población frente a regulador de conductas, y evaluar la confiabilidad de esa medición mediante dos procedimientos independientes.

5.2 Objetivos específicos

- OE1.** Construir un corpus de documentos oficiales bajo criterios de inclusión explícitos, verificables y aplicables por un tercero.
- OE2.** Pre-registrar el libro de códigos del eje $dézhì \leftrightarrow fǎy$ las predicciones del estudio antes de ejecutar cualquier medición.
- OE3.** Medir el eje por proyección bipolar sobre representaciones vectoriales del texto.
- OE4.** Medir el mismo eje mediante un panel de siete modelos de lenguaje de origen cultural mixto.
- OE5.** Estimar el acuerdo entre jueces y la magnitud del sesgo atribuible al origen del juez.
- OE6.** Someter el resultado a tres pruebas de confusión: región, tema del documento y estructura de Estado-partido.
- OE7.** Contrastar ambas vías y documentar sus coincidencias y desacuerdos.

6. Hipótesis

Las cuatro predicciones se registran en el repositorio antes de correr la medición. El registro es la marca de tiempo del *commit* que fija el libro de códigos y la configuración, verificable por cualquier tercero.

- H1.** China puntúa más alto que los seis países de tradición liberal en el eje $dézhì \leftrightarrow fǎ$.
- H2.** La diferencia no se explica por pertenecer a Asia oriental: los vecinos de tradición confuciana sin Estado-partido no reproducen el efecto.
- H3.** Los jueces de origen chino y los de origen occidental producen puntuaciones equivalentes.
- H4.** Los dos procedimientos de medición convergen en el mismo ordenamiento de países.

H4 se plantea como control de rutina. Su eventual rechazo sería el resultado más informativo del estudio, porque delimitaría el alcance de una familia de herramientas de uso creciente en educación comparada.

7. Método

7.1 Enfoque

Estudio comparativo de medición sobre texto de política pública. La unidad de análisis es el pasaje, no el documento ni el país: cada pasaje recibe un valor en un eje declarado por adelantado, y los valores se agregan por país.

7.2 Corpus

Un documento entra al corpus si cumple seis condiciones simultáneas.

Cuadro 1: Criterios de inclusión	
Criterio	Condición
C1. Autoría estatal	Adoptado por un órgano con autoridad pública, identificable por nombre
C2. Alcance nacional	Aplica al conjunto del territorio, salvo documentos subnacionales declarados como tales
C3. Sustancia	Trata la IA de manera central, no como mención incidental
C4. Vigencia	Rige a la fecha de corte del estudio
C5. Texto verbatim	Se dispone del texto oficial completo, no de una nota de prensa
C6. Par documental	El país aporta una estrategia de IA, un documento educativo, o ambos

Los criterios se redactan antes de revisar la vigencia y se aplican de forma retroactiva al corpus preexistente. Si la aplicación retroactiva expulsa documentos que ya estaban dentro, eso constituye evidencia de que el criterio hizo trabajo real.

Cada documento se divide en fragmentos de 500 caracteres con 50 de traslape y se almacena en una base vectorial con sus metadatos: país, región, año, género discursivo, órgano adoptante e identificador.

Cuadro 2: Corpus a la fecha de corte

País	Documento	Año	Frag.
China	15.º Plan Quinquenal (十五五), y ocho documentos más	2026	271
Canadá	<i>AI for All</i> [†]	2026	210
Estados Unidos	<i>America’s AI Action Plan</i> [†]	2025	156
Colombia	CONPES 4144 [†]	2025	764
Alemania	<i>KI-Strategie der Bundesregierung</i>	2020	230
Sudáfrica	Informe de la Comisión Presidencial 4IR	2020	1 303
Australia	<i>AI Action Plan</i>	2021	161
México	Ningún documento admisible (§ 7.3)	—	0

[†] Documento sustituido durante el estudio: los de Estados Unidos y Colombia por pérdida de vigencia (C4), el de Canadá por no ser el texto oficial de la estrategia (C5).

El Plan Quinquenal chino se incorpora como documento declarado para el análisis en profundidad de ese caso, no como parte del par documental de C6: ningún otro país del corpus dispone de un instrumento equivalente de planeación vinculante a cinco años.

7.3 El caso de México

México no forma parte del corpus. La razón no es de diseño muestral sino documental: ningún documento mexicano satisface los criterios de inclusión. Se revisaron cinco candidatos.

Cuadro 3: Candidatos mexicanos evaluados

Documento	Órgano	Criterio que incumple
Programa Sectorial de Educación 2025–2030	SEP, DOF sep. 2025	C3: cero menciones de IA en 222 páginas
Plan Nacional de Desarrollo 2025–2030	Presidencia, DOF abr. 2025	C3: una mención incidental en 79 páginas
Diez acciones sobre IA generativa en educación superior	SEP, abr. 2026	C1 y C5: recomendaciones presentadas en un acto público, sin texto adoptado
Agenda Nacional de IA 2024–2030	Alianza civil y Senado	C1: propuesta no adoptada por órgano de gobierno
Hacia una Estrategia de IA en México	C Minds, 2018	C1: autoría de sociedad civil

La única mención de inteligencia artificial en el Plan Nacional de Desarrollo la presenta

como herramienta de gestión administrativa («optimizar los servicios y mejorar el diseño de políticas públicas mediante el uso de herramientas analíticas como la inteligencia artificial»), no como objeto de política. C3 exige presencia en el título, sección propia o cincuenta menciones; una mención incidental es precisamente lo que el criterio excluye.

La ausencia es interpretable y conviene declararla como resultado y no como hueco. El Plan Nacional de Desarrollo mexicano y el Plan Quinquenal chino pertenecen al mismo género discursivo: el instrumento con que un Estado fija qué va a construir en un horizonte de cinco años. Cubren periodos casi idénticos. El chino menciona la inteligencia artificial cincuenta y dos veces y la educación cien; el mexicano, una y ninguna en relación con la primera. La comparación no requiere medición: la diferencia está en el conteo.

Por consistencia, tampoco se admite el reporte de resultados de la encuesta nacional sobre uso de IA generativa publicado por la SEP en 2026. Es un diagnóstico, no un curso de acción, y su análogo chino, el reporte de uso docente de generativa del mismo año, quedó fuera por la misma razón al aplicar C3 de forma retroactiva.

7.4 Muestreo

Se muestrean diez pasajes por país. El muestreo recupera los fragmentos semánticamente más cercanos a una consulta sobre gobernanza, de modo que la comparación se hace sobre material temáticamente equiparable. Fijar el número por país impide que un documento largo domine la comparación frente a uno breve.

7.5 Los seis ejes

El marco no se reduce a una oposición. La tradición confuciana ofrece un vocabulario de virtudes con el que se describe cada documento en seis dimensiones, todas aplicadas por igual a los siete países.

Los valores reportados son medianas estandarizadas contra la distribución del corpus completo: indican cuántas desviaciones típicas se aparta cada país del documento de política promedio.

China encabeza cinco de los seis ejes y Sudáfrica la empata en armonía; el único que China no encabeza es el ritual, donde Canadá queda por delante. Que un mismo país domine casi todo el perfil obliga a preguntar si los seis ejes miden seis constructos distintos o uno solo con seis nombres. Esa es la razón de que uno de ellos, y solo uno, se someta a doble medición.

Cuadro 4: Los seis ejes y lo que oponen

Eje	Nombre	Polo positivo frente a polo negativo
<i>rén</i> (仁)	Benevolencia	La persona y su dignidad, frente a la eficiencia instrumental
<i>lǐ</i> (礼)	Ritual	La norma compartida y el estándar, frente a su ausencia
<i>yì</i> (义)	Rectitud	Lo moralmente justo, frente a el provecho
<i>xiūshēn</i> (修身)	Cultivo de sí	La formación del carácter, frente a la credencial instrumental
<i>dézhì</i> ↔ <i>fǎ</i> (德治 / 法)	Virtud o norma	El Estado que forma personas, frente a el Estado que pone reglas exigibles
<i>hé</i> (和)	Armonía	El bien colectivo, frente a la autonomía individual

Cuadro 5: Perfil de los siete países en los seis ejes (Vía A)

Eje	China	Canadá	EUA	Colombia	Alemania	Sudáfrica	Australia
Benevolencia	0.97	0.34	0.09	-0.40	0.06	-0.07	0.11
Ritual	0.16	0.39	-0.84	-0.44	-0.23	0.30	0.04
Rectitud	1.07	0.17	0.48	-0.19	0.11	-0.13	-0.13
Cultivo de sí	0.51	0.30	-0.21	0.37	-0.05	-0.16	-0.11
Virtud o norma	0.85	0.78	-0.07	-0.20	0.08	0.03	0.45
Armonía	0.47	-0.28	-0.68	-0.39	-0.26	0.47	0.05




Figura 1: Perfil confuciano de China y Canadá en los seis ejes (Vía A). El anillo continuo marca el promedio del corpus; los punteados, media desviación típica por debajo y media y una por encima. Los perfiles casi coinciden en tres de los seis ejes, entre ellos el de virtud o norma.

Los cinco primeros ejes se miden únicamente por Vía A y su lectura es exploratoria: describen el perfil de cada país y generan hipótesis, pero ningún segundo procedimiento confirma que midan lo que sus etiquetas anuncian. El sexto, $dézhì \leftrightarrow fǎ$, es el que responde la pregunta de investigación y el único sometido a las dos vías.

7.6 El eje de medición

El eje $dézhì \leftrightarrow fǎ$ recibe además una escala ordinal de cinco valores, de -2 a $+2$, que es la que aplica el panel de jueces de la Vía B.

- +2 El Estado se presenta como cultivador y director moral de la sociedad: guía, educa, planifica y moviliza hacia metas colectivas que él mismo define. La educación y la tecnología aparecen como instrumentos de formación moral de la población.
- +1 El Estado planifica, dirige y exige alineamiento, pero sin lenguaje de cultivo moral explícito.
- 0 El pasaje no trata la relación entre poder estatal y persona.
- 1 La lógica liberal está presente pero es periférica o no restringe explícitamente al Estado.
- 2 Los derechos individuales operan como límite exigible sobre el propio Estado, con contrapesos institucionales explícitos.

7.7 Vía A: proyección sobre representaciones vectoriales

Cada fragmento se convierte en un vector de 384 dimensiones mediante un modelo multilingüe de representación de oraciones (Reimers and Gurevych, 2019). Para cada eje se redacta un conjunto de frases ancla en cada polo; el eje se define como la diferencia entre los centroides de ambos polos, y la puntuación de un fragmento es su proyección escalar sobre ese eje.

Las proyecciones se estandarizan contra la distribución del corpus completo, de modo que el valor reportado indica cuántas desviaciones típicas se aparta un país del texto de política promedio.

7.8 Vía B: panel de jueces

Siete modelos de lenguaje leen los mismos pasajes con el mismo libro de códigos y emiten cada uno una clasificación. Cuatro son de origen chino y tres de origen occidental. La partición

permite estimar si el origen cultural del instrumento sesga la medición del constructo cultural.

El panel trata a cada modelo como un evaluador falible dentro de un grupo, del mismo modo que una encuesta de expertos trata a cada experto. El valor no proviene de la infalibilidad de ninguno sino de la agregación de varios.

Cada juez recibe el pasaje, el libro de códigos completo y la instrucción de devolver un valor entero junto con una justificación breve. La temperatura se fija en cero. Las salidas crudas, incluidas las justificaciones, se almacenan en caché y se registran en una bitácora de auditoría.

Los pasajes en idiomas distintos del inglés se traducen antes de entregarse al panel, para que todos los jueces lean en el mismo idioma. Las traducciones se almacenan en caché con clave estable.

8. Plan de análisis

8.1 Acuerdo entre jueces

Se reportan cuatro medidas: acuerdo observado exacto y dentro de un punto, kappa de Fleiss, y alfa de Krippendorff en los niveles nominal, ordinal e intervalar.

El nivel ordinal es el pertinente. Confundir $+2$ con $+1$ es un error menor que confundir $+2$ con -2 , y solo el alfa ordinal recoge esa asimetría.

Los índices corregidos por azar se deprimen cuando la distribución se concentra en una categoría, aun con acuerdo observado alto. El eje de este estudio produce esa distribución, porque la mayoría de los pasajes de política pública no trata la relación entre poder estatal y persona. Por eso se reportan las cuatro medidas juntas: leer solo el kappa subestima la confiabilidad y leer solo el acuerdo observado la sobreestima.

8.2 Sesgo de origen

Para cada pasaje se calcula la media de los jueces occidentales y la de los chinos, y se toma la diferencia. La distribución de esa diferencia se estima por remuestreo con 5,000 réplicas y semilla fija.

El remuestreo se hace sobre **pasajes**, no sobre clasificaciones. Siete jueces que leen el mismo pasaje no son siete observaciones independientes, y tratarlos como tales produciría intervalos artificialmente estrechos.

8.3 Pruebas de confusión

Un valor alto en un país podría explicarse por causas ajenas al constructo. Se someten a prueba tres explicaciones alternativas mediante brazos de control declarados.

Cuadro 6: Brazos de control		
Explicación	Qué predice	Documentos del brazo
Región	Los vecinos de tradición confuciana suben	Corea del Sur, Japón, Singapur
Tema	Los documentos educativos no chinos suben	India, UNESCO
Estructura de Estado	Un Estado-partido confuciano no chino sube	Vietnam; Malasia como control

Los brazos de control **no** se agregan al conjunto principal de siete países. Hacerlo alteraría el diseño registrado. Entran como brazo declarado, y los valores de la comparación principal no se modifican.

8.4 Criterio de decisión

Las conclusiones se emiten a partir de contrastes con intervalo de confianza, no de umbrales fijos sobre valores puntuales. Un umbral convierte una cuestión de grado en un sí o un no, y puede producir un veredicto falso a partir de una diferencia que no se distingue de cero.

Un contraste sostiene una afirmación cuando su intervalo excluye el cero. Cuando lo incluye, el resultado se reporta como indistinguible, no como ausencia de efecto.

9. Objeciones anticipadas

9.1 El eje trata como opuestos lo que la doctrina china empareja

La doctrina oficial contemporánea del Partido Comunista de China sostiene que gobernar conforme a la ley (依法治国) y gobernar por la virtud (以德治国) son complementarios y se refuerzan mutuamente. El eje bipolar de este estudio los coloca en extremos opuestos.

La objeción es seria y se responde de tres maneras.

Primero, el eje mide encuadre, no doctrina. No pregunta si un Estado cree que ambos principios son compatibles; pregunta cómo se presenta la relación entre poder estatal y perso-

na en un pasaje concreto. Un Estado puede sostener la complementariedad y aun así redactar sus documentos de modo que el ciudadano aparezca como objeto de formación y no como titular de límites exigibles.

Segundo, la complementariedad predice un patrón observable. Si el discurso combinara ambos polos, los documentos jurídicos deberían puntuar cerca de cero mientras los educativos puntúan alto. Esa predicción es contrastable con los datos del estudio.

Tercero, la bipolaridad es una decisión de instrumento, no una tesis sobre China. La proyección bipolar requiere dos anclas contrapuestas; que el instrumento las oponga no implica que el objeto medido las oponga.

9.2 El acuerdo entre modelos no es validez

La literatura especializada advierte que el acuerdo alto entre modelos entrenados sobre datos superpuestos no constituye evidencia de que el constructo esté bien medido, y que los modelos tienen limitaciones documentadas para seguir libros de códigos sin ejemplos previos (Halterman and Keith, 2025).

Este estudio no puede refutar la objeción con su diseño actual. La respuesta es declararla como límite y especificar el procedimiento que la resolvería, descrito en la sección siguiente.

9.3 El riesgo de esencializar

Medir el discurso de un Estado en un eje construido desde su propia tradición filosófica corre el riesgo de tratar a ese país como un caso cultural y a los demás como el caso normal.

El diseño responde aplicando el mismo eje a los siete países por igual, incluyendo el brazo de control regional, y reportando si el efecto se extiende o no a los vecinos culturales. Un eje que solo se aplicara a un país describiría al analista, no al objeto.

10. Límites declarados

1. **Ausencia de ancla humana.** Ningún codificador humano valida las clasificaciones. Lo que se reporta es acuerdo entre instrumentos automáticos, es decir confiabilidad, no validez. Es la limitación que más restringe las afirmaciones posibles.
2. **Asimetría del corpus.** Los documentos varían en dos órdenes de magnitud de extensión. El muestreo por país impide que el volumen domine la comparación, pero no crea evidencia donde no la hay.

3. **Heterogeneidad de género.** El corpus mezcla estrategias, planes de acción, reportes de comisión y guías. El género se registra como metadato y se usa como control; no se elimina.
4. **Muestra intencional.** Siete casos elegidos por región no permiten generalización estadística a la población de países.
5. **Texto, no práctica.** El estudio mide encuadre discursivo en documentos oficiales. No dice nada sobre implementación ni sobre efectos en el aprendizaje.

11. Trabajo derivado

El paso que cierra la limitación central tiene nombre y costo estimable. El aprendizaje supervisado basado en diseño permite obtener inferencia estadísticamente válida combinando anotaciones automáticas sobre todo el corpus con una submuestra codificada por humanos, corrigiendo el sesgo del instrumento imperfecto sin renunciar a su cobertura (Egami et al., 2023).

Aplicado a este caso, requiere codificar a mano alrededor de cincuenta pasajes seleccionados al azar con el mismo libro de códigos, y usarlos para corregir las estimaciones del panel. Con dos codificadores independientes es trabajo de semanas.

12. Consideraciones éticas

Los documentos analizados son públicos y oficiales. No hay sujetos humanos ni datos personales, y la investigación no requiere consentimiento informado ni dictamen de comité de ética.

Tres compromisos de transparencia acompañan el trabajo:

1. El libro de códigos, la configuración y las predicciones son públicos y anteriores a la medición.
2. Las clasificaciones crudas, con la justificación de cada juez, quedan versionadas y son auditables.
3. Los desacuerdos entre las dos vías se reportan íntegros, no se resuelven eligiendo la vía que produzca el resultado más limpio.

Se adopta además una regla de higiene bibliográfica: ninguna referencia entra al archivo de citas sin haber consultado el texto completo. El precedente que la justifica es reciente y directo: en abril de 2026 se retiró un borrador de política nacional de inteligencia artificial porque su bibliografía contenía citas inventadas por un modelo de lenguaje.

13. Cronograma

Cuadro 7: Fases del proyecto

Fase	Actividad	Producto
1	Construcción del corpus y aplicación de criterios	Corpus versionado, bitácora de bajas
2	Redacción y registro del libro de códigos	<i>Commit</i> de pre-registro
3	Medición por Vía A sobre los seis ejes	Perfil por país
4	Medición por Vía B sobre el eje principal	Clasificaciones crudas y agregadas
5	Acuerdo, sesgo de origen e intervalos	Reporte de confiabilidad
6	Pruebas de confusión	Contrastes con intervalo
7	Contraste entre vías y redacción	Capítulos de resultados y discusión
8	Codificación humana de anclaje	Corrección por diseño supervisado

Las fases 1 a 7 están concluidas. La fase 8 queda como trabajo derivado.

14. Productos comprometidos

Cuadro 8: Productos y formato

Producto	Formato	Función
Tesis	$\text{\LaTeX} \rightarrow \text{PDF}$	Documento de grado
Artículo	$\text{\LaTeX} \rightarrow \text{PDF}$	Envío a revista arbitrada
Póster	HTML/CSS $\rightarrow$ PDF A0	Congreso, sesión de carteles
Presentación	Slidev $\rightarrow$ HTML y PDF	Defensa y ponencia
Protocolo	$\text{\LaTeX} \rightarrow \text{PDF}$	Este documento
Sitio del proyecto	HTML estático	Divulgación y reproducibilidad
Repositorio	Git público	Código, datos, libro de códigos, bitácora

Referencias

- Bareis, J. and Katzenbach, C. (2022). Talking AI into being: The narratives and imaginaries of national AI strategies and their performative politics. *Science, Technology, & Human Values*, 47(5):855–881.
- Egami, N., Hinck, M., Stewart, B. M., and Wei, H. (2023). Using imperfect surrogates for downstream inference: Design-based supervised learning for social science applications of large language models. In *Advances in Neural Information Processing Systems*. arXiv:2306.04746.
- Grimmer, J. and Stewart, B. M. (2013). Text as data: The promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis*, 21(3):267–297.
- Halterman, A. and Keith, K. A. (2025). Codebook LLMs: Evaluating LLMs as measurement tools for political science concepts. *Political Analysis*. arXiv:2407.10747.
- Pines, Y. (2023). Legalism in Chinese philosophy. In Zalta, E. N. and Nodelman, U., editors, *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, winter 2023 edition.
- Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992.
- Steiner-Khamisi, G. (2014). Cross-national policy borrowing: Understanding reception and translation. *Asia Pacific Journal of Education*, 34(2):153–167.
- UNESCO (2023). Guidance for generative AI in education and research. Technical report, United Nations Educational, Scientific and Cultural Organization, Paris.